

Аналитический отчёт: Drug Parameter Optimization

1. Постановка задачи

Набор данных содержит 1001 химическое соединение с 211 молекулярными дескрипторами (fingerprints, VSA-признаки, BCUT2D, EState, Kappa indices, описатели топологии) и тремя целевыми биологическими параметрами: IC50, CC50, SI.

Цели:

- Построить модели регрессии для прогнозирования абсолютных значений IC50, CC50, SI
- Построить модели классификации для предсказания «высокой» активности (выше медианы или заданного порога)
- Оценить информативность молекулярных дескрипторов для каждой задачи

2. Описание данных

Файл: data.xlsx, лист Sheet1 **Размерность:** 1001 строк × 214 колонок (211 признаков + 3 целевые)

2.1 Целевые переменные

Переменная	Mean	Median	Std	Min	Max	Skewness
IC50, mM	222.81	46.59	402.17	0.0035	4128.53	3.67

CC50, mM	589.11	411.04	642.87	0.70	4538.98	1.97
SI	72.51	3.85	684.48	0.01	15620.60	18.01

Все целевые переменные имеют правостороннюю асимметрию ($\text{skew} > 0$). IC50 и особенно SI обладают экстремальными хвостами распределения. После $\log_{10}$ -преобразования:

- IC50: $\text{skew} = -0.03$ (почему симметрично)
- CC50: $\text{skew} = -0.91$ (умеренная асимметрия)
- SI: $\text{skew} = 1.43$ (осталась правосторонняя асимметрия)

2.2 Признаки

Тип: все признаки числовые (int64 / float64), категориальных признаков нет.

Константные признаки (18): NumRadicalElectrons, SMR_VSA8, SlogP_VSA9, fr_N_O, fr_SH, fr_azide, fr_barbitur, fr_benzodiazepine, fr_diazo, fr_dihydropyridine, fr_isocyan, fr_isothiocyan, fr_lactam, fr_nitroso, fr_phos_acid, fr_phos_ester, fr_prisulfonamd, fr_thiocyan — все = 0. Удалены из дальнейшего анализа.

Пропущенные значения: максимум 3 пропущенных (0.3%) в 12 колонках: MaxPartialCharge, MinPartialCharge, MaxAbsPartialCharge, MinAbsPartialCharge и 8 колонок BCUT2D_*. Импутация медианой допустима.

Бинарные признаки: ~85 признаков fr_* принимают значения 0/1 (фрагменты молекул). Не требуют кодирования.

2.3 SI vs CC50/IC50

SI рассчитывается как $\text{CC50} / \text{IC50}$ для 410 из 1001 наблюдений (41%). Для остальных 591 значение SI отличается от этого соотношения, что указывает на использование экспериментально измеренных значений или альтернативной формулы расчёта.

3. EDA: ключевые выводы

3.1 Корреляции с целевыми переменными

IC50: топ-коррелированные признаки — VSA_EState4 (0.27), Chi2n (0.26), PEOE_VSA7 (0.26), Chi2v (0.25). Максимальная абсолютная корреляция с любым признаком — 0.27.

CC50: топ-коррелированные — MolMR (0.31), LabuteASA (0.31), MolWt (0.31), ExactMolWt (0.31), HeavyAtomCount (0.31). Максимум — 0.31.

SI: топ-коррелированные — BalabanJ (0.16), fr_NH2 (0.16), RingCount (0.12). Максимум — 0.16.

3.2 Мультиколлинеарность

Обнаружено множество пар признаков с $|r| > 0.9$, особенно среди VSA-признаков, BCUT2D-признаков и дескрипторов Кипара. Для деревьев и ансамблевых методов это не критично; для линейных моделей потребуется регуляризация.

3.3 Выводы по препроцессингу

1. Удалить 18 константных признаков
2. Импутировать пропуски медианой (12 колонок, максимум 3 пропуска)
3. Применить $\log_{1p}$ -преобразование к целевым переменным для регрессии (все skew > 1.5)
4. Масштабирование признаков StandardScaler необходимо для линейных моделей и KNN

4. Методология

4.1 Регрессия

Модели: DummyRegressor (mean, median), Ridge, Lasso, KNN, RandomForest (100 деревьев), HistGradientBoosting (200 итераций, max_depth=6).

Преобразование: log1p к целевой переменной при skew > 1.5.

Валидация: 5-fold CV (shuffle, random_state=42) + предсказание на обучающей выборке для оценки переобучения.

Метрики: MAE, RMSE, R² (среднее и std по фолдам).

4.2 Классификация

Задачи: IC50 > median, CC50 > median, SI > median, SI > 8.

Модели: DummyClassifier (stratified, most_frequent), LogisticRegression (class_weight=balanced), KNN, RandomForest (class_weight=balanced), GradientBoosting.

Валидация: Stratified 5-fold CV.

Метрики: accuracy, F1, ROC-AUC, PR-AUC (среднее и std по фолдам).

5. Результаты регрессии

5.1 IC50

Модель	MAE CV	R ² CV	RMSE CV
DummyMean	1.543	−0.004	1.860
DummyMedian	1.546	−0.009	1.865

Ridge	1.315	0.094	1.747
Lasso	1.285	0.202	1.641
KNN	1.170	0.336	1.509
RF	1.113	0.413	1.418
HGB	1.127	0.360	1.480

Лучшая модель: **RandomForest (R^2 CV = 0.41)**. Модель значительно превосходит базовые Dummy-модели, что подтверждает наличие предсказуемой зависимости между структурой и IC50.

5.2 CC50

Модель	MAE CV	R^2 CV	RMSE CV
DummyMean	1.297	-0.003	1.587
DummyMedian	1.265	-0.084	1.650
Ridge	1.003	0.021	1.539
Lasso	0.958	0.346	1.280
KNN	0.894	0.267	1.345
RF	0.856	0.422	1.203
HGB	0.843	0.405	1.221

Лучшая модель: **RandomForest (R^2 CV = 0.42)**. Аналогично IC50, ансамблевые методы превосходят линейные.

5.3 SI

Модель	MAE CV	R^2 CV	RMSE CV
DummyMean	1.143	-0.003	1.452

DummyMedian	1.096	-0.108	1.526
Ridge	1.024	0.123	1.348
Lasso	1.008	0.171	1.316
KNN	0.962	0.160	1.329
RF	0.885	0.328	1.186
HGB	0.911	0.273	1.233

Лучшая модель: **RandomForest (R^2 CV = 0.33)**. SI — самая сложная задача регрессии из-за экстремальной асимметрии (skew=18) и выбросов.

5.4 Важнейшие признаки (RF, log-масштаб)

IC50: VSA_EState8 (0.12), VSA_EState4 (0.07), VSA_EState6 (0.03), MolLogP (0.03).

CC50: NHOHCount (0.06), BCUT2D_MWLOW (0.05), Kappa1 (0.04), BCUT2D_MRLOW (0.03).

SI: VSA_EState6 (0.08), VSA_EState8 (0.06), qed (0.03), BCUT2D_CHGLO (0.03).

6. Результаты классификации

6.1 IC50 > median

Модель	Acc CV	ROC-AUC CV	PR-AUC CV	F1 CV
DummyStratified	0.464	0.465	0.484	—
DummyMostFrequent	0.500	0.500	0.500	—
LogReg	0.679	0.746	0.733	—

KNN	0.697	0.760	0.732	—
RF	0.706	0.772	0.767	—
HGB	0.705	0.770	0.764	—

Лучшая: **RandomForest (ROC-AUC = 0.77)**. Балансированный набор классов (~50/50) позволяет ассигурацию быть осмысленной метрикой.

6.2 CC50 > median

Модель	Acc CV	ROC-AUC CV	PR-AUC CV	F1 CV
DummyStratified	0.482	0.482	0.490	—
DummyMostFrequent	0.501	0.500	0.499	—
LogReg	0.736	0.816	0.806	—
KNN	0.733	0.825	0.802	—
RF	0.766	0.844	0.847	—
HGB	0.752	0.837	0.841	—

Лучшая: **RandomForest (ROC-AUC = 0.84)**. Лучший результат среди всех задач классификации.

6.3 SI > median

Модель	Acc CV	ROC-AUC CV	PR-AUC CV	F1 CV
DummyStratified	0.506	0.506	0.503	—
DummyMostFrequent	0.500	0.500	0.500	—
LogReg	0.647	0.696	0.676	—
KNN	0.654	0.716	0.688	—
RF	0.672	0.716	0.727	—

HGB	0.645	0.696	0.690	—
-----	-------	-------	-------	---

Лучшая: **RandomForest (ROC-AUC = 0.72)**. Умеренное качество из-за высокой вариабельности SI.

6.4 SI > 8

Модель	Acc CV	ROC-AUC CV	PR-AUC CV	F1 CV
DummyStratified	0.537	0.488	0.353	—
DummyMostFrequent	0.643	0.500	0.357	—
LogReg	0.651	0.686	0.568	—
KNN	0.677	0.686	0.565	—
RF	0.698	0.725	0.648	—
HGB	0.692	0.719	0.624	—

Лучшая: **RandomForest (ROC-AUC = 0.73)**. Классы несбалансированы (~36%/64%), поэтому ассурасу завышена за счёт предсказания «низкого» класса. PR-AUC (0.65) — более информативная метрика.

6.5 Важнейшие признаки (RF, классификация)

IC50 > median: VSA_EState8 (0.02), BCUT2D_MRLOW (0.02), BCUT2D_MWLOW (0.02).

CC50 > median: NHOHCount (0.02), BCUT2D_CHGLO (0.02), PEOE_VSA7 (0.02).

SI > median: MinEStateIndex (0.02), BCUT2D_MRLOW (0.02), VSA_EState4 (0.02).

SI > 8: FractionCSP3 (0.02), SMR_VSA7 (0.02), MaxEStateIndex (0.02).

7. Сравнение моделей

7.1 Регрессия

Задача	Лучшая модель	R ² CV	Лучший признак
IC50	RandomForest	0.41	VSA_EState8
CC50	RandomForest	0.42	NHOHCount
SI	RandomForest	0.33	VSA_EState6

RandomForest consistently best across all regression tasks. HistGradientBoosting — второй по качеству. Линейные модели (Ridge, Lasso) значительно уступают нелинейным методам.

7.2 Классификация

Задача	Лучшая модель	ROC-AUC
IC50 > median	RandomForest	0.77
CC50 > median	RandomForest	0.84
SI > median	RandomForest	0.72
SI > 8	RandomForest	0.73

CC50 > median — самая предсказуемая задача (ROC-AUC = 0.84). SI классификации — наименее предсказуемые из-за высокой дисперсии селективного индекса.

8. Ограничения

1. Ограниченная предсказуемость абсолютных значений: R²

< 0.45 для всех регрессионных задач указывает на то, что молекулярные дескрипторы не содержат всей информации, необходимой для точного прогнозирования абсолютных концентраций. Вероятно, важна стереохимия, конформации и другие структурные факторы.

2. **SI — самая сложная цель:** Экстремальная асимметрия (skew=18) и выбросы (max=15620 при median=3.85) делают SI наименее предсказуемой целевой переменной.
3. **Нет внешнего тестового набора:** Все результаты получены через cross-validation на одном наборе данных. Необходима валидация на независимом наборе соединений.
4. **Отсутствие SMILES/структурных формул:** Данные содержат только числовые дескрипторы. Использование графовых нейронных сетей или трансформеров для молекул могло бы улучшить качество.

9. Рекомендации по дальнейшему исследованию

1. **Градиентный бустинг с тонкой настройкой:** XGBoost / LightGBM с поиском гиперпараметров могут превзойти RandomForest.
2. **Ensemble methods:** Комбинация RF + HGB + KNN через stacking.
3. **Feature engineering:** Создание производных признаков (отношения между дескрипторами, взаимодействия).
4. **Молекулярные графы:** Использование SMILES для построения молекулярных графов и применения GNN.
5. **Анализ неопределённости:** Bayesian regression или quantile regression для оценки доверительных интервалов.

10. Итоговые выбранные модели

Задача	Модель	Ключевая метрика
Регрессия IC50	RandomForestRegressor(100)	R^2 CV = 0.41
Регрессия CC50	RandomForestRegressor(100)	R^2 CV = 0.42
Регрессия SI	RandomForestRegressor(100)	R^2 CV = 0.33
Класс. IC50 > median	RandomForestClassifier(100)	ROC-AUC = 0.77
Класс. CC50 > median	RandomForestClassifier(100)	ROC-AUC = 0.84
Класс. SI > median	RandomForestClassifier(100)	ROC-AUC = 0.72
Класс. SI > 8	RandomForestClassifier(100)	ROC-AUC = 0.73

Во всех задачах RandomForest с class_weight=balanced (для классификации) показал наилучшие результаты по ROC-AUC и R^2 .